

Imię i nazwisko	Wiktoria Sakowska (274931)
Nazwa uczelni	Uniwersytet Gdański
Nazwa wydziału	Matematyki, Fizyki i Informatyki
Kierunek	Informatyka Ogólnoakademicka
Prowadząca	mgr Laura Grzonka
Nazwa ćwiczenia	Projekt 3
Data zajęć	20.05.2025 r.
Data oddania	20.05.2025 r.

Detekcja halucynacji w odpowiedziach LLM

Dokumentacja projektu

Programowanie w języku Python — Projekt II (Uczenie maszynowe)

Spis treści

1	Opis projektu	3
2	Dataset	3
2.1	HaluEval — Hallucination Evaluation Benchmark	3
2.2	Struktura datasetu	3
2.3	Unifikacja subsetów	4
3	Preprocessing	4
3.1	Czyszczenie danych	4
3.2	Inżynieria cech	4
3.3	Wektoryzacja TF-IDF	4
3.4	Podział danych	5
4	Eksploracyjna analiza danych (EDA)	5
4.1	Rozkład labeli	5
4.2	Rozkład długości tekstu	6
4.3	Korelacja cech	7
4.4	Violin plots kluczowych cech	7
4.5	Najczęstsze słowa	8
5	Modele uczenia maszynowego	8
5.1	Przegląd modeli	8
5.2	Wyniki	9
5.3	Porównanie metryk	9
5.4	Macierze błędów	10
5.5	Krzywe ROC	11
5.6	Krzywa uczenia — MLP	12
6	Wybór najlepszego modelu	12
7	Struktura projektu	12
8	Uruchomienie	13
9	Podział pracy	14
9.1	Praca samodzielna	14
9.2	Z pomocą AI	14
10	Bibliografia	14
10.1	Sztuczna inteligencja	14
10.2	Dataset	14
10.3	Biblioteki	14
10.4	Źródła internetowe	15

1 Opis projektu

Projekt dotyczy detekcji halucynacji w odpowiedziach dużych modeli językowych (LLM). Halucynacja to sytuacja, w której model generuje treści brzmiące wiarygodnie, ale niezgodne z faktami lub kontekstem źródłowym.

Zadanie polega na klasyfikacji binarnej: dla danej odpowiedzi modelu językowego określamy, czy jest ona **poprawna** (label 0) czy **halucynowana** (label 1).

Główne założenia projektu:

- Wykorzystanie benchmarku HaluEval — dedykowanego datasetu do ewaluacji halucynacji LLM.
- Unifikacja 4 subsetów danych do jednego formatu binarnej klasyfikacji.
- Preprocessing tekstu z inżynierią cech (10 cech numerycznych + TF-IDF).
- Porównanie 6 algorytmów uczenia maszynowego o różnych architekturach.
- Wizualizacja wyników: macierze błędów, krzywe ROC, krzywe uczenia, porównanie metryk.
- Wybór najlepszego modelu z uzasadnieniem.

2 Dataset

2.1 HaluEval — Hallucination Evaluation Benchmark

Projekt wykorzystuje dataset **HaluEval** (Li et al., 2023), opublikowany na konferencji EMNLP 2023. Jest to benchmark stworzony specjalnie do ewaluacji halucynacji w modelach językowych.

Źródło: <https://huggingface.co/datasets/pminervini/HaluEval> (licencja Apache 2.0).

2.2 Struktura datasetu

Dataset składa się z 4 subsetów o różnych formatach:

Subset	Rekordów	Opis
QA	10 000	Pytania i odpowiedzi — każdy wiersz zawiera poprawną i halucynowaną odpowiedź
Dialogue	10 000	Odpowiedzi w kontekście dialogu
Summarization	10 000	Podsumowania dokumentów
General	4 507	Odpowiedzi ChatGPT z naturalnym labellem (yes/no)
Razem	34 507	

2.3 Unifikacja subsetów

Subsety QA, Dialogue i Summarization mają kolumny `right_answer` / `hallucinated_answer` — z każdego wiersza tworzymy 2 rekordy (poprawna + halucynacja), co daje zbalansowane klasy. Subset General ma naturalny label `hallucination`: `yes/no`.

Po unifikacji i usunięciu duplikatów/NaN: **61 887 rekordów** (50,3% poprawnych, 49,7% halucynacji).

3 Preprocessing

3.1 Czyszczenie danych

Pipeline preprocessingu obejmuje:

1. Unifikacja 4 subsetów do wspólnego formatu: `text`, `label`, `source`, `context`, `knowledge`.
2. Usunięcie rekordów z brakującymi wartościami (NaN) w kolumnach `text` i `label`.
3. Usunięcie pustych tekstów i duplikatów (po kolumnie `text`).
4. Normalizacja białych znaków i konwersja do lowercase.

W wyniku czyszczenia usunięto 2 620 rekordów (4,1%), pozostało 61 887.

3.2 Inżynieria cech

Dla każdego tekstu obliczono 10 cech numerycznych:

Cecha	Opis	Poprawne	Halucynacje
<code>text_len</code>	Długość tekstu (znaki)	184,2	211,3
<code>word_count</code>	Liczba słów	31,0	35,3
<code>avg_word_len</code>	Średnia długość słowa	5,09	5,01
<code>sentence_count</code>	Przybliżona liczba zdań	2,42	2,30
<code>exclamation_count</code>	Liczba wykrzykników	0,063	0,046
<code>question_mark_count</code>	Liczba znaków zapytania	0,113	0,087
<code>uppercase_ratio</code>	Stosunek wielkich liter	0,071	0,055
<code>unique_word_ratio</code>	Stosunek unikalnych słów	0,913	0,899
<code>digit_count</code>	Liczba cyfr	2,02	1,59
<code>punctuation_ratio</code>	Stosunek interpunkcji	0,029	0,029

Najważniejsze obserwacje: halucynacje są średnio dłuższe (+14,7%), ale zawierają mniej cyfr (−21,5%), mniej wielkich liter (−21,9%) i mniej znaków zapytania (−22,8%).

3.3 Wektoryzacja TF-IDF

Tekst przekształcono za pomocą `TfidfVectorizer` z parametrami:

- `max_features=10 000` — ograniczenie do 10 000 najważniejszych cech
- `ngram_range=(1, 2)` — unigramy i bigramy

- `min_df=3`, `max_df=0.95` — filtrowanie rzadkich i bardzo częstych słów
- `sublinear_tf=True` — logarytmiczne skalowanie TF

Cechy TF-IDF połączono z 10 cechami numerycznymi, dając łącznie **10 010 cech**.


3.4 Podział danych

Dane podzielono na zbiór treningowy (80%) i testowy (20%) ze stratyfikacją po labelu:

Zbiór	Razem	Label 0	Label 1
Train	49 509	24 918	24 591
Test	12 378	6 230	6 148


4 Eksploracyjna analiza danych (EDA)

4.1 Rozkład labeli




Rysunek 1: Rozkład labeli — ogólny (lewo) i per subset (prawo). Klasy są prawie idealnie zbalansowane (50,3% vs 49,7%). Subset General jest jedynym niezbalansowanym (82% poprawnych vs 18% halucynacji).

4.2 Rozkład długości tekstu




Rysunek 2: Rozkład liczby słów per label (lewo) i per subset (pravo). Halucynacje są średnio dłuższe, szczególnie w subsecie Summarization.

4.3 Korelacja cech




Rysunek 3: Heatmapa korelacji cech z labelem. Najsilniejsza korelacja z labelem: uppercase_ratio $(-0,14)$ i unique_word_ratio $(-0,07)$. Silne korelacje między cechami: text_len i word_count $(0,99)$, word_count i unique_word_ratio $(-0,84)$.

4.4 Violin plots kluczowych cech



Rysunek 4: Rozkład kluczowych cech vs label. Różnice widoczne, ale nie dramatyczne — uzasadnia to użycie TF-IDF (treść tekstu) jako głównej reprezentacji.

4.5 Najczęstsze słowa



Rysunek 5: Top 20 słów w poprawnych odpowiedziach (lewo) i halucynacjach (prawo). Halucynacje częściej zawierają słowo „actually”, „despite”, „starred”, „wrote” — słowa sugerujące konfabulację szczegółów.

5 Modele uczenia maszynowego

5.1 Przegląd modeli

Wytrenowano 6 modeli reprezentujących różne klasy algorytmów:

Model	Typ algorytmu	Kluczowe hiperparametry
Logistic Regression	Liniowy, regularyzacja L2	C=1.0, solver=lbfgs, max_iter=1000
Naive Bayes	Probabilistyczny	alpha=0.1 (wygładzanie Laplace'a)
Linear SVM	Liniowy, max-margin	C=1.0, max_iter=2000, kalibracja CV=3
Random Forest	Ensemble (bagging)	200 drzew, max_depth=30, min_samples_split=5
XGBoost	Ensemble (boosting)	200 drzew, lr=0.1, max_depth=5, subsample=0.8
MLP	Sieć neuronowa	Warstwy: (256, 128), ReLU, Adam, early stopping

Różnorodność modeli:


- **Logistic Regression** — liniowy baseline, modeluje granicę decyzyjną jako hiperpłaszczyznę; regularyzacja L2 zapobiega overfittingowi na dużej liczbie cech TF-IDF.
- **Naive Bayes** — zakłada niezależność cech (naiwne założenie), ale działa dobrze na danych tekstowych; parametr alpha kontroluje wygładzanie Laplace'a.

- **Linear SVM** — szuka hiperpłaszczyzny maksymalizującej margines między klasami; parametr C kontroluje kompromis bias-variance.
- **Random Forest** — ensemble niezależnych drzew decyzyjnych (bagging); max_depth ogranicza głębokość drzewa, zapobiegając overfittingowi.
- **XGBoost** — drzewa budowane sekwencyjnie (boosting), każde koryguje błędy poprzedniego; learning_rate kontroluje tempo uczenia, subsample dodaje losowość.
- **MLP** — sieć neuronowa z 2 warstwami ukrytymi; ReLU jako nieliniowa aktywacja, Adam jako adaptacyjny optymalizator, early stopping zapobiega overfittingowi.

5.2 Wyniki


Model	Accuracy	F1	Precision	Recall	ROC AUC
MLP	0.8501	0.8507	0.8421	0.8595	0.9242
XGBoost	0.8468	0.8490	0.8319	0.8668	0.9270
Random Forest	0.8198	0.8292	0.7831	0.8811	0.9110
Linear SVM	0.8148	0.8110	0.8221	0.8003	0.8899
Logistic Regression	0.8019	0.7969	0.8120	0.7824	0.8773
Naive Bayes	0.7231	0.7183	0.7261	0.7106	0.7884

5.3 Porównanie metryk




Rysunek 6: Porównanie metryk wszystkich 6 modeli. MLP i XGBoost osiągają najwyższe wyniki we wszystkich metrykach.

5.4 Macierze błędów




Rysunek 7: Macierze błędów dwóch najlepszych modeli: MLP (lewo) i XGBoost (prawo). MLP ma lepszą równowagę między false positives (991) i false negatives (864).




Rysunek 8: Macierze błędów: Random Forest (lewo) i Naive Bayes (prawo). RF ma wysoki recall (0.88) kosztem precision; NB ma najsłabsze wyniki.

5.5 Krzywe ROC



Rysunek 9: Krzywe ROC — porównanie modeli. XGBoost (AUC=0.927) i MLP (AUC=0.924) dominują. Naive Bayes (AUC=0.788) jest wyraźnie słabszy.

5.6 Krzywa uczenia — MLP



Rysunek 10: Krzywa uczenia MLP. Luka między train F1 (~ 0.93) a validation F1 (~ 0.82) wskazuje na umiarkowany overfitting. Validation F1 stabilizuje się od ~ 6000 próbek, co sugeruje, że więcej danych mogłoby poprawić wyniki.

6 Wybór najlepszego modelu

Najlepszy model: MLP (Multi-Layer Perceptron)

Uzasadnienie wyboru:

1. **Najwyższe F1 score (0.8507)** — F1 jest główną metryką, ponieważ w detekcji halucynacji zależy nam zarówno na wykrywaniu halucynacji (recall), jak i na unikaniu fałszywych alarmów (precision).
2. **Najlepsza równowaga precision/recall** — MLP ma precision=0.8421 i recall=0.8595, czyli nie poświęca jednego kosztem drugiego (w przeciwieństwie do Random Forest: precision=0.78 vs recall=0.88).
3. **Najwyższa accuracy (0.8501)** — ogólna trafność klasyfikacji.
4. **Rozsądny czas treningu (38.5s)** — znacznie szybszy od XGBoost (109.1s) przy porównywalnych wynikach.

Warto zauważyć, że XGBoost ma nieznacznie wyższy ROC AUC (0.927 vs 0.924), co oznacza lepszą zdolność rozróżniania klas przy różnych progach. W zastosowaniu praktycznym warto byłoby rozważyć oba modele.

7 Struktura projektu

```

project03/
|-- data/
|   |-- raw/                # surowe dane HaluEval
|   '-- processed/         # dane po preprocessingu
|-- models/                # zapisane modele .pkl
|-- notebooks/
|   '-- 01_eda.py           # Exploratory Data Analysis
|-- results/
|   |-- figures/            # wykresy (14 plikow)
|   '-- metrics/           # metryki modeli (CSV)
|-- src/
|   |-- __init__.py
|   |-- preprocessing.py    # unifikacja i czyszczenie danych
|   |-- features.py         # TF-IDF, feature engineering, split
|   |-- evaluation.py       # metryki, confusion matrix, ROC
|   '-- models.py           # definicje i trening 6 modeli ML
|-- setup_project.py        # pobieranie danych i tworzenie
    struktury
|-- requirements.txt
|-- .gitignore
'-- README.md

```

8 Uruchomienie

```

# 1. Srodowisko wirtualne
python3 -m venv venv
source venv/bin/activate

# 2. Instalacja zaleznosci
pip install -r requirements.txt

# 3. Pobranie danych i setup
python setup_project.py

# 4. Preprocessing
python src/preprocessing.py

# 5. Feature extraction
python src/features.py

# 6. EDA (opcjonalnie)
python notebooks/01_eda.py

# 7. Trening i ewaluacja modeli
python src/models.py

```

9 Podział pracy

9.1 Praca samodzielna

- Koncepcja projektu — wybór tematu (detekcja halucynacji LLM), dobór datasetu
- Wybór i dobór modeli ML z różnorodnymi architekturami
- Interpretacja wyników — analiza metryk, wybór najlepszego modelu z uzasadnieniem
- Analiza EDA — wnioski z wykresów, identyfikacja wzorców w danych
- Generowanie kodu wizualizacji (wykresy matplotlib/seaborn)
- Dokumentacja (README, niniejszy dokument)

9.2 Z pomocą AI

- Wsparcie przy pisaniu kodu — generowanie szkieletu modułów
- Debugowanie błędów (ścieżki plików, kompatybilność seaborn)
- Pomoc przy strukturyzacji projektu i planowaniu commitów

10 Bibliografia

10.1 Sztuczna inteligencja

Narzędzie	Model	Firma	Zastosowanie	Dostęp
Claude	Claude Opus 4	Anthropic	Wsparcie przy kodowaniu, debugowanie, planowanie	V 2025

10.2 Dataset

Li, J. et al. (2023). *HaluEval: A Large-Scale Hallucination Evaluation Benchmark for Large Language Models*. EMNLP 2023. <https://github.com/RUCAIBox/HaluEval>. Dostęp: V 2025.

Dataset: <https://huggingface.co/datasets/pminervini/HaluEval> (licencja Apache 2.0). Dostęp: V 2025.

10.3 Biblioteki

Nazwa	Wersja	Strona	Dostęp
scikit-learn	≥ 1.3.0	https://scikit-learn.org/	V 2025
pandas	≥ 2.0.0	https://pandas.pydata.org/	V 2025
numpy	≥ 1.24.0	https://numpy.org/	V 2025
matplotlib	≥ 3.7.0	https://matplotlib.org/	V 2025
seaborn	≥ 0.12.0	https://seaborn.pydata.org/	V 2025
datasets (HuggingFace)	≥ 2.19.0	https://huggingface.co/docs/datasets/	V 2025
nltk	≥ 3.8.0	https://www.nltk.org/	V 2025

10.4 Źródła internetowe

Tytuł	URL	Dostęp
scikit-learn — User Guide	https://scikit-learn.org/stable/user_guide.html	V 2025
scikit-learn — TfidfVectorizer	https://scikit-learn.org/stable/modules/generated/sklearn.feature_extraction.text.TfidfVectorizer.html	V 2025
scikit-learn — MLPClassifier	https://scikit-learn.org/stable/modules/generated/sklearn.neural_network.MLPClassifier.html	V 2025
matplotlib — Tutorials	https://matplotlib.org/stable/tutorials/	V 2025
seaborn — Gallery	https://seaborn.pydata.org/examples/	V 2025
HuggingFace Datasets — Docs	https://huggingface.co/docs/datasets/	V 2025